

### 2013中国数据库技术大会

DATABASE TECHNOLOGY CONFERENCE CHINA 2013 大数据数据库架构与优化数据治理与分析









基于SQL Server的大数据解决方案 设计及实现

> 孙巍 高级项目经理 Customer Advisory Team 微软亚太研发集团云创新中心



### About CAT













## 议程 Agenda

- 大数据时代
- 你真的需要大数据吗?
- 关于大数据的一些事
- 微软有大数据方案吗?







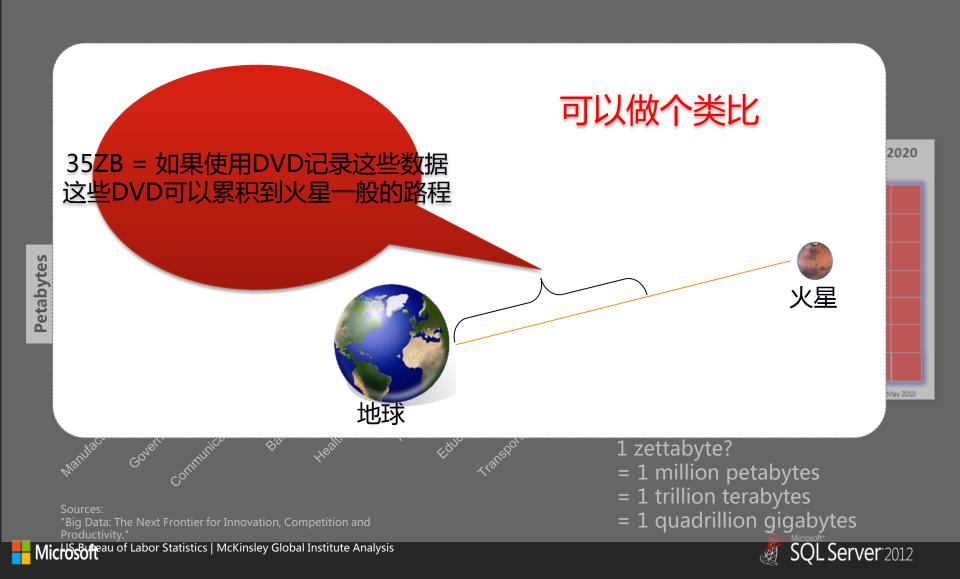


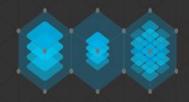
## 大数据到底意味着什么





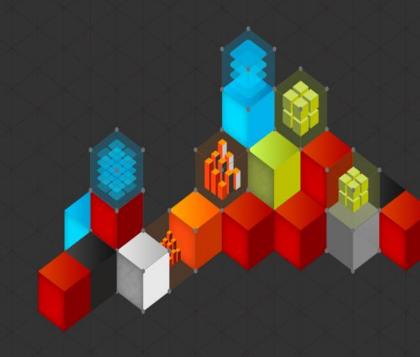
## 大数据的一些统计





## 你真的需要大数据吗?

IT领域目前最热门的话题





### 你真的需要大数据吗?

• Yes, 我们所有人都需要

我们的品牌和产品的口碑如何?





我如何基于天气和交通 流量的模式优化我的车 队?





#### 但是。。。

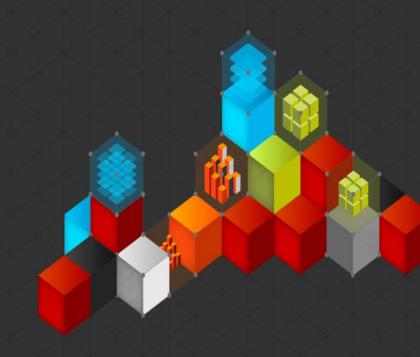
- 构建 OR 使用
  - 构建一个大数据平台或解决方案
  - 使用大数据平台或解决方案
  - 80/20
- 大数据是一项系统工程,不能仅仅是购买或使用某个产品就可以解决问题
- 大数据需要很多很多资源和技术
- 大数据离我们很远吗?







## 关于大数据的一些事





## 希望你还没有晕





## NOSQL 为什么是这个名字...







这个不是在说SQL不应该再被使用或者说SQL已死





## NOT Only SQL

应该是重新认识一些问题找到更好的方法





# Why? Nosql?

- 更好的数据模型灵活性
  - · 将JSON作为一种数据模型
  - 没有"schema first"的需求
- 从采集的数据中快速获得洞察力
- 宽松的一致性模型例如 eventual consistency
- •除了C/Java,在学校没学过什么其他的东西
  - · 讨厌例如SQL这类声明式的语言

## 2类主流的NOSQL 系统

#### •键/值存储

- 例如: MongoDB, CouchBase, Cassandra Wind
- 灵活的数据模型,
- 通过键的Hash支持
- 基于键获取单一的

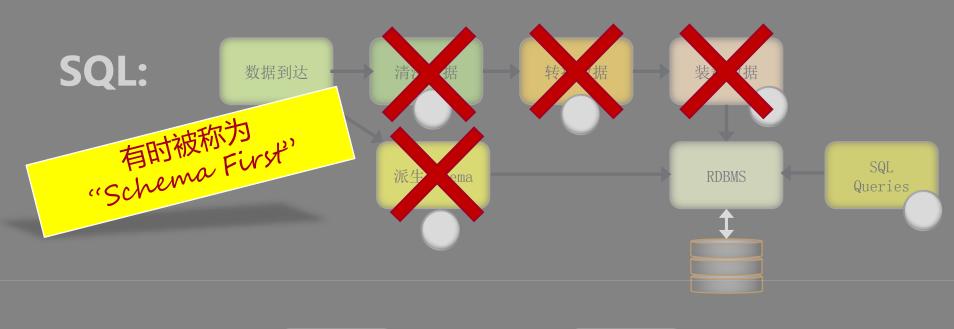
NOSQL OLTP

#### Hadoop

- 为存储和处理海量数据而设计的可扩展容错框架
- 典型的没有数据模
- 记录存储在分布式

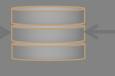
NOSQL data warehousing

#### WHY?? REDUCE TIME TO INSIGHT



NoSQL:

数据到达



应用程序

有时被称为"Schema Later"

不需要清洗

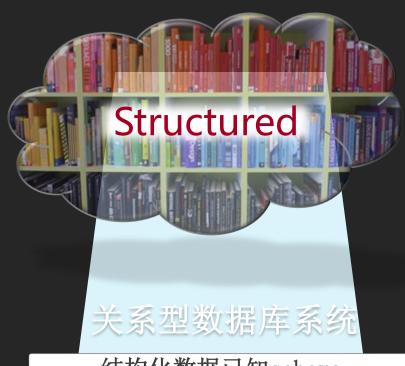
不需要ETL!

不需要装载!

当数据落地之后就可以分析



### 现实中存在的2个世界



结构化数据已知schema

ACID

Transactions

SQL

强制一致性

ETL

需要长时间获得洞察力

成熟并且稳定



非结构化或半结构化数据,没有schema

No ACID

No transactions

No SQL

最终一致性

No ETL

快速获得洞察力

Beta, alpha, 0.x···



#### 微软的HADOOP策略 MAKE HADOOP ENTERPRISE READY

● 构建微软自己的Hadoop分 \_\_\_\_发版本 • 向 Apache 基金会提交变更

免费下载

● 为Windows和Azure而优化

• AD与Systems Center的集成

Hadoop-as-a-service-on-Azure

● 专注于 .NET 开发者

Visual Studio集成

• 支持C#

● 企业就绪的差异化

• 性能和可扩展

高可用

易于使用



## 关系型数据库还是Hadoop?

(未来谁是主宰?)

## 这是一个错误的问题

关系型数据库和Hadoop是基于<mark>不同的需求</mark>而设计出 的系统





## SQL Server 2012 Parallel Data Warehouse 软硬件整合优化的并行数据仓库一体机



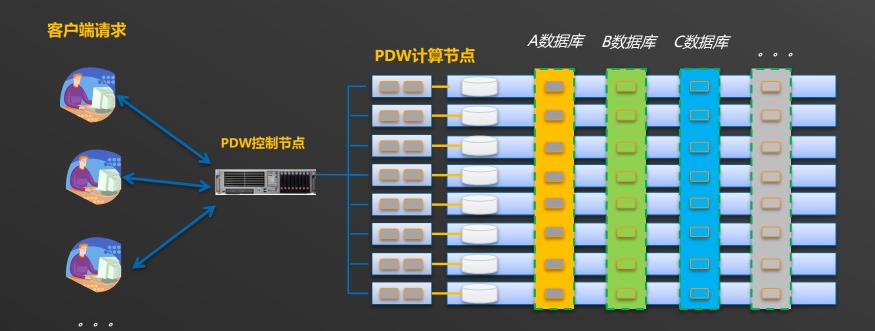
- 从TB到PB 的高可扩展性平台
- 使用MPP架构实现卓越的可扩展性
- 硬件厂商的选择



- · 通过使用遵循行业标准的硬件降低成本
- 与Microsoft 商业智能工具的深度集成
- 充分利用最新软件技术
  - Windows Server 2012 Storage Spaces
  - Windows Server 2012 Hyper-V
  - ➤ SQL Server 2012 xVelocity 列存储



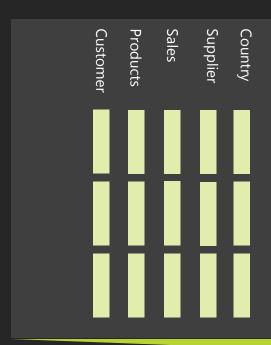
## 数据仓库一体机并行处理架构 多节点、分布式、无共享





#### 列存储技术提供新一代性能





#### 列存储技术提供强大性能

- 可更新的聚集列存储
- 数据以列形式存储
- · 内存优化技术提供新一代性能
- · 灵活可更新,同时满足批量导入或小量数据的加载更新需求

庭50X 性能提升 高至 王缩比例 节省时间和 成本

实时 数据仓库



## PDW**数据仓库一体机** VS. HADOOP**数据仓库** ( HIVE )

#### 性難测试

- 基于9台HP服务器的集群, 双路CPU, 4核心, 16GB内存, 4块 SAS 数据磁盘
- 软件
  - SQL Server PDW Version "next"
    - 1台控制节点, 8 计算节点
  - Windows Hadoop Version 0.20.203, Hive Version 0.7.1
    - 1 命名节点, 8 数据节点
  - Windows Server 2008
- 基于TPC-H (SF 800)的测试表
  - lineitem: 612GB, 48亿条记录
  - orders: 140GB, 12亿条记录





#### PDW数据仓库一体机 VS. HADOOP数据仓库(HIVE)









	数据仓库一体机系统	Hadoop
计算模型	- 具有交易的概念 - 面向交易的工作特性 - 强制ACID	- 具有任务的概念 - 面向任务的工作特性 - 没有并发控制
数据模型	- 带有已知架构的结构化数据 - 读写模式	- 所有的数据都可以是任何格式 - 非结构化或半结构化 - 只读模式
<b>一种性性</b>	- 以一体机形式购买	- 通过廉价硬件自行组装
容错	- 假设极少发生故障 - 没有查询级别的容错	- 假设经常发生故障 - 简单且高效的容错
关键特性	- 效率 , 优化	- 可扩展性和灵活性

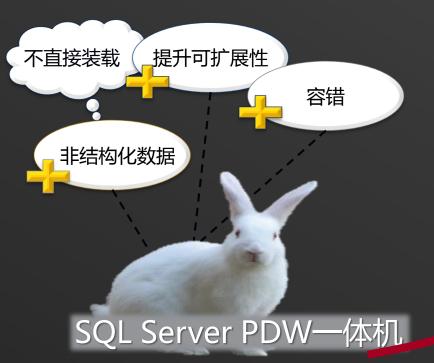


## 单纯的关系型数据库系统或单纯的Hadoop 将不再是默认的选择

# 我们有没有更好的选择?



## 我们可以断言

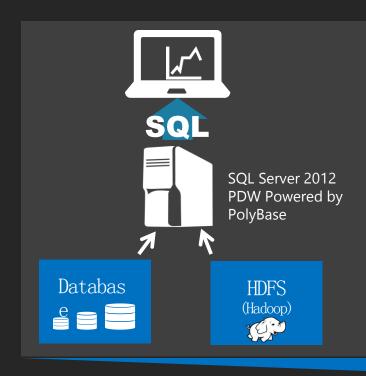






#### POLYBASE: 数据处理的突破性技术





#### 统一查询,结构化和非结构化数据

- · 查询关联Hadoop表和关系型数据库表
- ・ 采用标准SQL语言
  - Select, From Where

沿用现有 SQL技能









## 道了. · 关系型与半结构化的整合



## 总结

- 大数据这个话题不仅仅只是Hadoop
- 未来并不是一个某一个架构或方案能够一统天下的格局,需要对大数据有一个清晰的认识
- 微软积极参与大数据的方案和设计

